UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA
DAN ILMU PENGETAHUAN ALAM
PRODI S1 SAINS DATA

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

TAHUN AKADEMIK 2026/2027 SEMESTER GASAL
TUGAS DATA WRANGLING & PIPELINE ANALYSIS DATA

Mata Kuliah	:	Data Wrangling
Dosen Pengampu	:	Dr. Belgis Ainatul Iza, S.Si., M.Mat.
Kelas	:	2025B, 2025C
Dataset Lampiran	:	Terlampir

Petunjuk Pengerjaan & Pengumpulan

1. **Struktur Penulisan Laporan:**
   - **Halaman Judul:** Judul Tugas, Nama, NIM, Kelas, Nama Dosen.
   - **Bab I. Data Preparation & Ingestion:** Penjelasan singkat mengenai struktur data awal dan pemeriksaan kualitas data.
   - **Bab II. Langkah-Langkah Data Wrangling & Analisis (Task 1 – Task 5):** Setiap *task* harus memuat *code block* Python, tampilan *output*/grafik, serta interpretasi singkat (1–2 kalimat).
   - **Bab III. Kesimpulan Analisis:** Ringkasan temuan utama dari indikator kesehatan Indonesia.

   Tangkapan layar (*screenshot*) atau salinan kode Python beserta hasil *output* (tabel/grafik) dimasukkan ke Laporan secara rapi.
2. **Berkas yang Wajib Dikumpulkan (3 File):**
   a. File Laporan: Dokumen PDF.
   b. File Kode: File Notebook/Script Python (`.ipynb` atau `.py`).
   c. File Data Bersih: File CSV hasil transformasi data dari Task 2 (`dataset_long_format.csv`).
3. **Ketentuan Pengumpulan:**
   - Kompres ketiga berkas di atas ke dalam satu folder terkompresi (`.zip`) dengan format nama file: `Tugas_DataWrangling_NIM_NamaLengkap.zip`.
   - Unggah berkas ke LMS sesuai dengan tenggat waktu yang telah ditentukan.

Task 1: Data Ingestion & Data Structuring

1. Baca file lampiran Excel menggunakan library Pandas.
2. Pecah dataset master menjadi 2 Dataframe terpisah:
   - **Tabel Dimensi Wilayah** (`df_dim_wilayah`): Kolom `['Kabupaten/Kota', 'Provinsi', 'Pulau', 'Wilayah Indonesia', 'Tipe Wilayah']` (pastikan *unique/distinct*).
   - **Tabel Fakta Indikator** (`df_fakta_kesehatan`): Kolom `['Kabupaten/Kota', 'Tahun']` beserta 23 indikator kesehatan/sosio-ekonomi lainnya.
3. Tampilkan ringkasan informasi dataset (*shape*, *data types*, dan *missing values*) dari kedua tabel tersebut.

Task 2: Data Restructuring & Reshaping (Pivoting & Melting)

1. **Unpivoting (Wide to Long):** Ubah format tabel master dari bentuk *wide* menjadi *long format/tidy data* dengan susunan kolom: `['Kabupaten/Kota', 'Tahun', 'Nama_Indikator', 'Nilai']`. Simpan hasil data bersih ini ke dalam file `dataset_long_format.csv`.

2. **Pivoting (Long to Wide):** Buat tabel *panel data* khusus untuk indikator **Prevalensi Stunting (%)**, di mana **baris** menunjukkan `Kabupaten/Kota` dan **kolom** menunjukkan `Tahun` (2015, 2018, 2019, 2021, 2023).

Task 3: Subsetting, Filtering, & Merging

1. Filter dan tampilkan seluruh kabupaten/kota pada tahun 2023 yang memenuhi dua kondisi sekaligus: `Prevalensi Stunting (%) > 0.30` dan `Penduduk Miskin (%) > 0.10`.

2. Lakukan penggabungan (*merge/join*) antara `df_dim_wilayah` dan `df_fakta_kesehatan` di Python menggunakan teknik **Left Join** berdasarkan kunci `Kabupaten/Kota`.

Task 4: Group Processing, Feature Engineering, & Group Normalization

1. **Group Aggregation:** Hitung nilai rata-rata (*mean*) dan standar deviasi (*std*) untuk indikator `AKI (per 100rb Kelahiran)` dan `Prevalensi Stunting (%)` secara hierarkis berdasarkan tingkatan: `Wilayah Indonesia` → `Pulau` → `Tipe Wilayah`.

2. **Group Normalization:** Lakukan normalisasi skala (Min-Max Scaling 0–1) pada variabel `Kepadatan Penduduk (Jiwa/km2)` dan `PDRB per Kapita (Juta Rp)` yang dikelompokkan berdasarkan masing-masing `Pulau` (`groupby('Pulau')`).

3. **Categorical Binning:** Buat kolom baru bernama `Kategori_Stunting` berdasarkan nilai `Prevalensi Stunting (%)` pada tahun 2023 dengan ketentuan:

   - < 0.20 : Rendah
   - $0.20 - 0.30$: Sedang
   - > 0.30 : Tinggi / Kritis

Task 5: Outlier Detection, Correlation Analysis, & Group Plotting

1. **Outlier Detection:** Hitung dan identifikasi kabupaten/kota yang merupakan *outlier* (pencilan) pada variabel `PDRB per Kapita (Juta Rp)` dan `Kepadatan Penduduk (Jiwa/km2)` menggunakan metode Interquartile Range (IQR) atau Z-Score untuk data tahun 2023.

2. **Correlation Analysis:** Buat matriks korelasi (*Pearson correlation*) antara indikator sosio-ekonomi (`Penduduk Miskin (%)`, `PDRB per Kapita`) dengan indikator pelayanan & hasil kesehatan (`Prevalensi Stunting (%)`, `Cakupan BPJS/JKN (%)`, `Rasio Bed RS`). Tampilkan menggunakan visualisasi Heatmap (`seaborn`).

3. **Group Plotting / Visualization:**

   - Buat visualisasi Boxplot untuk membandingkan sebaran `Prevalensi Stunting (%)` antar `Pulau` pada tahun 2023.
   - Buat visualisasi Line Plot yang menampilkan tren rata-rata `Prevalensi Stunting (%)` dari tahun 2015 hingga 2023 berdasarkan `Wilayah Indonesia` (Barat, Tengah, Timur).